Graphe CV-Job : Modélisation Bipartite, Enrichissement Sémantique par LLM et Classification Hybride

Projet Master 2 - Graph Mining

Gaies-Nader / Harzallah-Mohamed

Université Paris Dauphine | PSL

26 février 2026

Objectifs du Projet

- **Modélisation :** Construire un graphe biparti reliant des CV (nœuds) à des offres d'emploi (nœuds Jobs).
- **Enrichissement :** Utiliser la puissance des **LLM** pour détecter des liens sémantiques que la structure brute ne voit pas.
- **Classification :** Prédire le niveau d'expérience (Junior, Intermédiaire, Senior) via une approche hybride (Topologie + Texte).

Enjeu

Dépasser le simple matching par mots-clés pour comprendre la position d'un candidat dans l'écosystème du marché.

Méthodologie : La Construction du Graphe

Le Dataset :

- 20 CV générés (Data, Web, DevOps).
- 10 Jobs cibles.
- Attributs : Compétences, Expérience, Domaine.

Structure :

- Graphe biparti initial.
- Analyse de densité (0.06).

[Visualisation du Graphe Biparti CV-Job]
Outil : NetworkX

Analyse Structurelle & Communautés

- **Détection de Communautés :** Algorithme de **Louvain** pour identifier les clusters de compétences au niveau global.
- **Centralité d'Intermédiation (Betweenness) :** Identification des profils "ponts" ou polyvalents.
- **Analyse Micro-graphe :** Calcul de la densité interne des compétences propres à chaque CV.

Résultat clé

Les profils à forte centralité d'intermédiation sont souvent les plus résilients face aux changements de marché.

Enrichissement par LLM (Sentence-BERT)

- **Embeddings :** Utilisation de `all-MiniLM-L6-v2` pour transformer le texte brut en vecteurs (384 dimensions).
- **Similarité Cosinus :** Calcul de la proximité sémantique entre CV et Jobs.
- **Fusion :**

$$\text{Lien } (i, j) \text{ ajouté si } \text{SimCos}(V_{CV_i}, V_{Job_j}) > \text{Seuil } (0.75)$$

Indice Adamic-Adar : Utilisé en parallèle pour prédire des liens basés sur le voisinage structurel.

Classification des Profils

Le Modèle : Random Forest Classifier

- **Features combinées :**
  1. Embeddings sémantiques (Texte).
  2. Degré de nœud et Centralité (Structure).
  3. Appartenance communautaire.

Métrique	**Score**
Précision globale	86%
Recall (Senior)	90%

Table – Performance de l'approche hybride

Discussion & Perspectives

Limites rencontrées :

- Complexité calculatoire des centralités sur de très grands graphes ($O(VE)$).
- Dépendance à la qualité des prompts/embeddings du LLM.

Futures pistes :

- **Graph Neural Networks (GNN) :** Utiliser GraphSage pour apprendre les représentations de voisinage.
- **Graphes Temporels :** Modéliser l'évolution de carrière dans le temps.

Conclusion

L'union fait la force :

- **LLM** apporte la compréhension du langage.
- **Graph Mining** apporte la compréhension du contexte et de l'influence.

Merci pour votre attention !

Des questions ?