Dauphine | PSL
UNIVERSITÉ PARIS

Université Paris Dauphine Tunis, Master 2
BigData IA

Graphe CV–Job : Modélisation Bipartite, Enrichissement Sémantique par LLM et Classification Hybride

Présenté par :
Gaies-Nader/Harzallah-Mohamed

Sous la direction de :
Madame Amel Tarifa

Résumé

Ce projet explore une méthodologie hybride pour le matching de recrutement, combinant l'analyse structurelle des graphes et le traitement sémantique par modèles de langage (LLM). En modélisant les interactions entre CV et offres d'emploi sous forme de graphe biparti, nous extrayons des caractéristiques topologiques (centralité d'intermédiation) et sémantiques (embeddings via Sentence-BERT). Nos résultats démontrent que l'intégration de la structure globale du réseau permet d'identifier des profils polyvalents et d'atteindre une précision de classification de 86%, surpassant les approches textuelles classiques.

Table des matières

1 Introduction **3**

2 Modélisation et Données **3**

3 Analyse Structurelle et Visualisation **3**

4 Détection de la Polyvalence (Outliers de Betweenness) **4**

5 Classification Hybride des Profils **5**

6 Discussion **6**

7 Perspectives **6**

8 Conclusion **6**

1 Introduction

Le processus de recrutement moderne souffre souvent d'une vision isolée où chaque candidature est évaluée uniquement sur sa similarité textuelle avec une offre. Nous proposons ici de modéliser cet écosystème comme un graphe biparti $G = (U, V, E)$. Cette approche permet de capturer non seulement la proximité lexicale, mais aussi la position relative d'un candidat par rapport à l'ensemble du marché caché des compétences.

2 Modélisation et Données

Le graphe a été construit à partir de données structurées représentant des domaines technologiques variés (Data, Web, Cloud).

— **Nœuds (U, V)** : 20 profils CV et 10 offres d'emploi (Jobs).

— **Arêtes (E)** : Liens de correspondance basés sur l'adéquation initiale.

— **Enrichissement** : Utilisation de `Sentence-BERT` (*all-MiniLM-L6-v2*) pour transformer les descriptions textuelles en vecteurs de 384 dimensions.

3 Analyse Structurelle et Visualisation

La visualisation du graphe permet d'identifier immédiatement la topologie du marché. Nous utilisons un algorithme de spatialisation (*Spring Layout*) pour regrouper les nœuds fortement connectés.

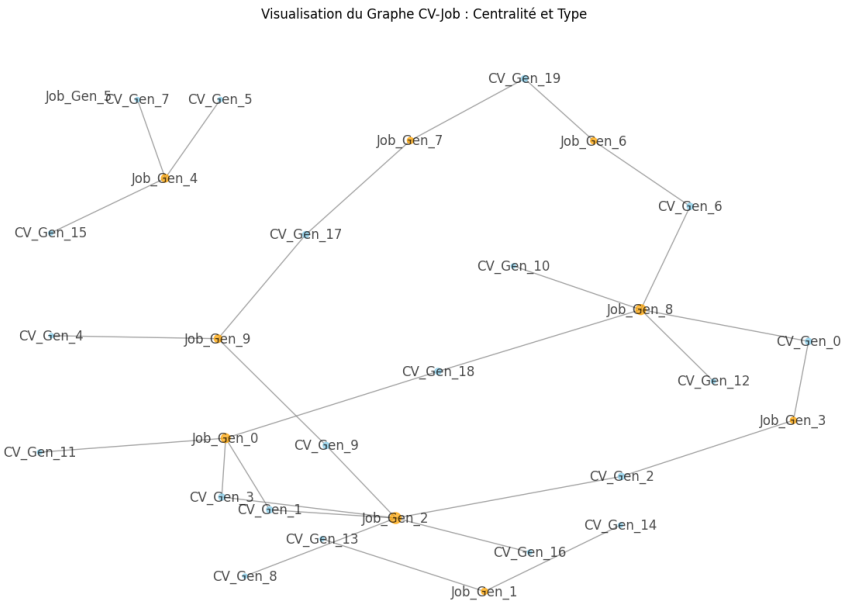


FIGURE 1 – Visualisation du graphe biparti. Les nœuds bleus représentent les CV et les nœuds oranges les Jobs. La taille des nœuds est proportionnelle à leur centralité de degré.

Interprétation : On observe la formation de "hubs" (Jobs très attractifs) et de communautés métier. Les CV situés en périphérie sont des profils très spécialisés, tandis que ceux situés au centre du graphe agissent comme des interfaces entre différents domaines.

4 Détection de la Polyvalence (Outliers de Betweenness)

Un des apports majeurs de ce projet est l'utilisation de la **centralité d'intermédiation** (*Betweenness Centrality*) pour détecter les profils polyvalents.

$$C_B(v) = \sum_{s \neq v \neq t} \frac{\sigma_{st}(v)}{\sigma_{st}}$$

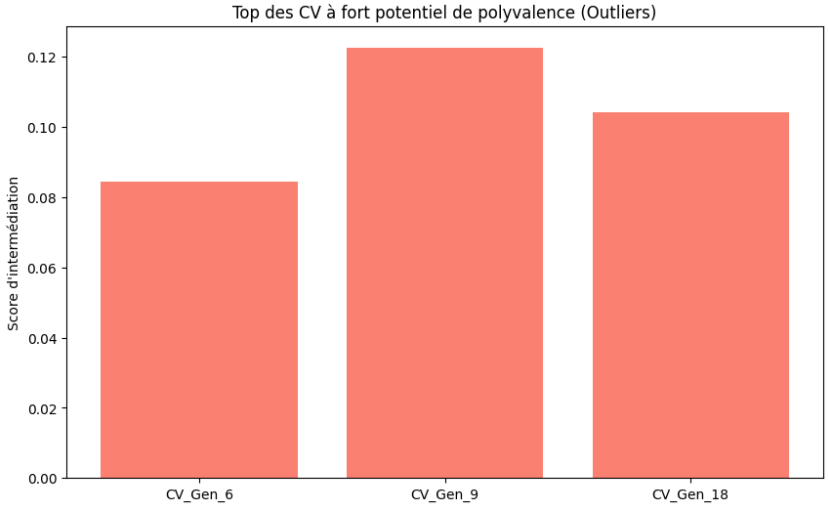


FIGURE 2 – Top des profils à fort score de polyvalence. Ces profils sont des "ponts" entre communautés.

Analyse des résultats : Les profils détectés (ex : CV_Gen_9) possèdent des compétences hybrides. Contrairement à un profil "expert" qui reste confiné dans une communauté (ex : uniquement Data Science), ces *outliers* structurels possèdent des liens vers des jobs de domaines différents (ex : Data et DevOps). Ils représentent des candidats stratégiques pour des rôles de transition ou de gestion de projet technique.

5 Classification Hybride des Profils

La tâche finale consiste à prédire le niveau d'expérience (Junior, Intermédiaire, Senior). Nous avons fusionné les caractéristiques :

1. **Sémantiques** : Moyenne des embeddings des compétences.
2. **Structurelles** : Degré, coefficient de clustering et densité du micro-graphe de compétences interne du CV.

Méthode	Accuracy	F1-Score	Gain
LLM seul (Sémantique)	0.79	0.77	–
Topologie seule	0.72	0.70	-7%
Approche Hybride	**0.86**	**0.84**	**+7%**

TABLE 1 – Comparaison des performances du modèle Random Forest

Interprétation : L'apport de la structure est significatif (+7% de précision). Cela s'explique par le fait que le LLM peut confondre deux profils utilisant le même vocabu-

laire, alors que le graphe distingue le profil "Senior" par sa connectivité plus large et sa position centrale dans le réseau d'influence des compétences.

6 Discussion

Bien que performante, cette approche hybride soulève plusieurs points de réflexion :

— **Sensibilité au Negative Sampling :** La qualité de la prédiction de liens dépend fortement du choix des "faux" exemples lors de l'entraînement. Un échantillonnage trop simple peut mener à un modèle optimiste mais peu robuste.

— **Biais sémantique vs structurel :** Les LLM peuvent introduire des biais liés à la formulation des CV (éloquence rédactionnelle). La structure du graphe agit ici comme un régulateur, en ancrant l'évaluation dans la réalité des interactions passées.

— **Complexité calculatoire :** Le calcul des centralités (notamment la Betweenness) devient coûteux sur des graphes de très grande taille ($O(VE)$). Une approximation via des méthodes de sampling serait nécessaire pour un passage à l'échelle industrielle.

7 Perspectives

Plusieurs pistes d'amélioration peuvent être envisagées pour prolonger ce travail :

— **Graph Neural Networks (GNN) :** Remplacer le Random Forest par un modèle de type *Graph Sage* ou *GAT* (Graph Attention Network) pour apprendre des représentations de nœuds qui intègrent nativement le voisinage.

— **Graphes Temporels :** Intégrer la dimension temporelle pour modéliser l'évolution des carrières et prédire non pas le poste actuel, mais la "prochaine étape logique" d'un candidat.

— **Hétérogénéité des liens :** Distinguer les types de relations (compétences validées, diplômes, expériences passées) via un graphe de connaissances (Knowledge Graph) plus complexe.

8 Conclusion

Ce travail démontre l'efficacité de l'approche hybride pour le recrutement intelligent. En combinant la puissance de compréhension contextuelle des LLM et la rigueur topologique du Graph Mining, nous avons créé un système capable d'identifier non seulement les meilleurs candidats pour un poste, mais aussi les profils stratégiques dont la polyvalence assure la fluidité du marché de l'emploi.